

Avaliação 1 - Ciência de dados - Web scraping e regressão linear para previsão de preços de imóveis

Fonte de dados e método de coleta

Os dados foram coletados do portal **VivaReal**, com foco em apartamentos, casas e coberturas à venda em Belo Horizonte (MG), em 05/10/2026. Como o site monta os resultados com JavaScript, a coleta foi feita com a biblioteca **Playwright** (Node.js), no script `scraper.js`. O script abre a busca, espera os cartões dos imóveis carregarem, rola a página e lê de cada cartão o preço, a área, os quartos, os banheiros, as vagas, o bairro, o tipo e o link do anúncio. Foram percorridas as 10 primeiras páginas de resultados (300 cartões, dos quais 286 eram imóveis únicos), com pausas aleatórias de 2,5 a 5,5 segundos entre as páginas.

Estatísticas descritivas da amostra

Antes da análise, o script `limpeza.py` tratou os dados assim:

- Conversão de tipos: textos como "R\$ 1.200.000" e "75 m²" foram transformados em números (1200000,0 e 75,0);
- Remoção do único imóvel sem preço;
- Imputação de vagas: os 11 anúncios sem o campo de vagas receberam 0, pois o site omite esse campo quando o imóvel não tem garagem;
- Remoção de 4 outliers extremos, fora do intervalo de $Q1 - 3 \times IQR$ a $Q3 + 3 \times IQR$ no preço e no preço por m²;
- Criação da variável preço por m², obtida pela divisão do preço pela área.

A amostra final tem **281 imóveis em 104 bairros**: 199 apartamentos, 35 coberturas e 47 casas. O bairro Buritis sozinho concentra 16,7% dos anúncios.

Variável	Média	Mediana	Desvio-padrão	Mínimo	Máximo
Preço (R\$)	985.735	850.000	615.644	239.069	3.504.000
Área (m²)	128,3	96,0	99,1	25,0	1.000,0
Preço/m² (R\$)	9.031	8.064	4.725	1.279	25.209
Quartos	2,8	3	0,9	1	7
Banheiros	2,3	2	1,1	1	8
Vagas	2,1	2	1,3	0	10

Gráficos da EDA




Figura 1 – Distribuição do preço e do preço por m², com a mediana.





Figura 2 – Matriz de correlação (Pearson). Figura 3 – Preço nos 10 bairros com mais anúncios.




Figura 4 – Área × preço com reta de tendência, em escala linear e log-log.

Quais variáveis parecem mais correlacionadas com o preço? Banheiros (0,61), vagas (0,57) e quartos (0,55) aparecem antes da área (0,48) na correlação de Pearson. A área, porém, fica subestimada: na correlação de Spearman ela chega a 0,62. Isso acontece por causa das casas grandes com preço por m² baixo (R\$ 4,5 mil/m² nas casas, contra R\$ 9,3 mil nos apartamentos). A localização também pesa muito: a mediana de preço vai de R\$ 490 mil (Planalto) a R\$ 1,5 milhão (Savassi).

A relação é linear? Só em parte. A variação do preço cresce junto com a área e existem poucos imóveis muito caros puxando a média. Em escala logarítmica a relação fica mais reta (a correlação entre área e preço sobe de 0,48 para 0,59), por isso também testamos um modelo com log do preço.

Especificação do modelo e métricas

O modelo escolhido é uma **regressão linear múltipla (OLS)** que prevê o preço a partir de área, quartos, banheiros, vagas, tipo do imóvel (casa ou apartamento), regional da cidade e lançamento. A localização entrou por **One-Hot Encoding**: primeiro testamos os bairros, mas como a maioria tinha poucos anúncios, os bairros foram agrupados nas 9 regionais administrativas de BH, o que deu resultados melhores e mais estáveis. Também incluímos uma interação entre área e casa, porque nas casas a área informada parece ser a do terreno, e a variável **lançamento** (imóveis novos ou na planta, identificados pelo link do anúncio), que só foi descoberta depois da primeira avaliação no teste.

A amostra foi dividida em treino (80%, 224 imóveis) e teste (20%, 57 imóveis). As escolhas foram feitas por validação cruzada (5 partes, repetida 3 vezes) usando só o treino. Comparamos a regressão linear com **Ridge** e **Lasso** (que ficaram praticamente empatados, então mantivemos a linear, mais simples), com um modelo **log-log** (log do preço e da área, com a correção de Duan para converter as previsões de volta para reais) e, só como referência, com um **Random Forest**.

Modelo	R ² (CV)	RMSE (CV)	MAE (CV)	R ² (teste)	RMSE (teste)	MAE (teste)
Linear, sem lançamento (1ª)	0,584	R\$ 405.155	R\$ 284.986	0,599	R\$ 349.131	R\$ 243.669
Log-log, sem lançamento (1ª)	0,357	R\$ 503.546	R\$ 294.193	0,671	R\$ 316.113	R\$ 219.193
Linear OLS (principal)	0,674	R\$ 358.607	R\$ 265.451	0,658	R\$ 322.444	R\$ 238.265
Linear Ridge	0,672	R\$ 359.633	R\$ 264.370	—	—	—
Linear Lasso	0,666	R\$ 363.095	R\$ 267.071	—	—	—
Log-log + Duan (complementar)	0,589	R\$ 402.288	R\$ 245.018	0,782	R\$ 257.115	R\$ 197.789
Random Forest (referência)	0,682	R\$ 354.248	R\$ 244.192	—	—	—

A regressão linear explica cerca de 2/3 da variação dos preços e quase empata com o Random Forest, um modelo bem mais complexo. No teste, o log-log foi melhor; mesmo assim mantivemos a linear, porque o critério foi definido antes do teste e, no treino, ela errou menos nos imóveis grandes. As duas primeiras linhas mostram a primeira avaliação, antes da variável de lançamento; como essa variável entrou depois, o segundo resultado no teste não é totalmente independente.

Multicolinearidade (VIF): quartos, banheiros, vagas e regionais ficaram abaixo de 3. A área ficou em 9,98, mas isso vem da própria interação área × casa; separando a área por tipo, o valor cai para 3,33. Os resíduos não têm variância constante (teste de Breusch-Pagan), por isso usamos erros-padrão robustos (HC3).




Figura 5 – Real × previsto no conjunto de teste.




Figura 6 – Resíduos × previsto (ajuste no treino).



Figura 7 – QQ-plot dos resíduos padronizados.

Interpretação dos coeficientes

Mantidas as demais características iguais:

- **Área:** cada m² adicional eleva o preço do apartamento em cerca de **R\$ 4.475** (intervalo de 95%: R\$ 2.934 a R\$ 6.016). Nas casas, a área quase não muda o preço, o que reforça que ali ela é a área do terreno;

- **Banheiro:** cada banheiro a mais acrescenta cerca de **R\$ 131 mil** (ou 10%);
- **Vaga:** cada vaga a mais acrescenta cerca de **R\$ 164 mil** (ou 14%);
- **Localização:** um imóvel na regional Centro-Sul custa cerca de **R\$ 399 mil (32%) a mais** que um igual na regional Oeste; no Norte, cerca de R\$ 249 mil (30%) a menos;
- **Casa:** com a mesma área, uma casa vale cerca de 29,5% menos que um apartamento;
- **Lançamento:** imóveis novos ou na planta custam cerca de **R\$ 598 mil (72%) a mais**. Parte disso pode ser erro de medida, já que o anúncio mostra o preço "a partir de";
- **Quartos** não tiveram efeito significativo: com a área fixa, um quarto a mais só divide o mesmo espaço.

Limitações: amostra pequena, viés de anúncios, seleção geográfica

- **Preço pedido não é preço de venda:** usamos o valor anunciado, que costuma ficar acima do valor fechado no negócio;
- **Amostra pequena:** 281 imóveis, abaixo dos 300 sugeridos, vindos só das 10 primeiras páginas do site;
- **Viés de anúncios:** o Buritis concentra 16,7% da amostra, o que reflete a ordem do site e não o mercado; nas casas, a área informada parece ser a do terreno;
- **Seleção geográfica:** a amostra cobre só Belo Horizonte, e o agrupamento dos bairros em regionais foi feito manualmente;
- **Variáveis que faltaram:** o cartão do anúncio só traz preço, área, cômodos, vagas e endereço, então o modelo não sabe a idade do prédio nem como o imóvel está por dentro;
- **Precisão:** o modelo erra tipicamente de 20% a 25% e, em 4 dos 57 imóveis do teste, previu valores abaixo do menor preço do treino.

Considerações éticas sobre scraping

- **robots.txt e termos de uso:** verificados manualmente em 05/10/2026. O robots.txt bloqueia para robôs as buscas com os parâmetros onde= e tipos=, usados pelo scraper, e a cláusula 9.1 dos Termos de Uso do Grupo OLX (dono do VivaReal) proíbe usar robôs para copiar elementos dos sites. **A coleta, portanto, não respeitou o robots.txt nem os termos de uso;**
- **Proteção contra robôs:** o site bloqueou o navegador automático (erro 403). O scraper abriu o navegador visível e escondeu a marca de automação, contornando essa proteção;
- **LGPD:** só foram coletados dados dos imóveis, o endereço e o link, sem nomes, telefones ou e-mails. Como endereço e link podem identificar o anunciante, a base não será publicada;
- **Carga e uso acadêmico:** pausas de 2,5 a 5,5 segundos entre as páginas. A coleta só se justifica como exercício acadêmico em pequena escala e não deve ser repetida dessa forma; o caminho certo seria pedir autorização ao site ou usar uma fonte que permita a coleta.